

PROJETO - FASE 3

INTELIGÊNCIA COMPUTACIONAL

ALEXANDRE FERREIRA - 2021138219


CARLOS PINTO - 2021155627



DESCRIÇÃO DO PROBLEMA

Avaliar a existência de focos de incêndio e a sua classificação quanto a presença de fumo, chama ou nenhum destes com base em imagens.

Este problema tem aplicações práticas em várias áreas, incluindo vigilância de incêndios, detecção de fumos e análise de imagens gerais.



DESCRIÇÃO DAS METODOLOGIAS

GSA

Nesse contexto, as soluções candidatas são tratadas como corpos com massa, e a atração gravitacional entre esses corpos é utilizada para explorar o espaço de pesquisa na procura melhores soluções.

No código, o GSA é aplicado para otimizar os hiperparâmetros da rede neuronal, como o número de épocas de treino e o número de neurónios nas camadas ocultas.

PSO

No Pso cada solução candidata é representada por uma partícula que se move no espaço de pesquisa, ajustando a sua posição com base na sua própria experiência e na experiência das partículas vizinhas.


No código, o PSO é usado para encontrar os melhores conjuntos de hiperparâmetros para otimizar o desempenho da rede neuronal.

TRANSFER LEARNING

Foi utilizada a arquitetura pré-treinada **Xception** como base para a construção da rede neuronal.

A **Xception** é uma rede neuronal convolucional eficaz para tarefas de classificação de imagens.

Este modelo pré-treinado é adaptado para a tarefa específica em questão, ajustando os pesos durante o treino com o conjunto de dados fornecido.



ESTRUTURA DO CÓDIGO



Inicialização

São feitas as importações de bibliotecas e declarações de variáveis necessárias

Tratamento de dados

O dataset é dividido entre teste, treino e validação

Criação do modelo

Caso o utilizador não queira utilizar um modelo guardado, o modelo é criado com o modelo Xception e as top layers

Treino e avaliação

É realizado o treino do modelo e a sua avaliação para ser melhorada pelos algoritmos PSO

Resultados

São avaliados os melhores modelos encontrados pelos PSO e estes são guardados

DISCUSSÃO DE RESULTADOS

GSA

Camada 2 :
número de neuronios -> 25
função de ativação -> relu

Camada 3 :
número de neuronios -> 32
função de ativação -> relu

Camada 4:
número de neuronios ->3
função de ativação -> softmax

Especificidade: 0.8444
Sensibilidade: 0.8908
f-measure: 0.8670
accuracy: 0.8444

AUC (OvR): 0.9218
AUC (OvO): 0.8919

Matriz de Confusão:
[[33 0 0]
[0 37 0]
[14 0 6]]

Relatório de Classificação:

	precision	recall	f1-score	support
0	0.70	1.00	0.82	33
1	1.00	1.00	1.00	37
2	1.00	0.30	0.46	20
accuracy			0.84	90
macro avg	0.90	0.77	0.76	90
weighted avg	0.89	0.84	0.82	90

PSO

Camada 2 :
número de neuronios -> 23
função de ativação -> relu

Camada 3 :
número de neuronios -> 17
função de ativação -> relu

Camada 4:
número de neuronios ->3
função de ativação -> softmax

Especificidade: 0.4222
Sensibilidade: 0.7757
f-measure: 0.5468
accuracy: 0.4222


AUC (OvR): 0.7347
AUC (OvO): 0.7190

Matriz de Confusão:
[[33 0 0]
[37 0 0]
[15 0 5]]

Relatório de Classificação:

	precision	recall	f1-score	support
0	0.39	1.00	0.56	33
1	1.00	0.00	0.00	37
2	1.00	0.25	0.40	20
accuracy			0.42	90
macro avg	0.80	0.42	0.32	90
weighted avg	0.78	0.42	0.29	90

HIPERPARÂMETROS



DISCUSSÃO DE RESULTADOS

O GSA obteve uma accuracy significativamente superior em comparação com o PSO (84.44% vs. 42.22%).

Na especificidade e sensibilidade, o GSA também superou o PSO.

O PSO apresentou um desempenho inferior, especialmente na classe 1, onde a precisão foi prejudicada.

Ambos os algoritmos apresentaram uma AUC (Área sob a Curva ROC) considerável, indicando uma boa capacidade de discriminação.

TRANSFER LEARNING

Transfer Learning superou o treino sem transfer learning.

A inclusão do conhecimento prévio da Xception contribuiu para um melhor desempenho geral.

- **Sem transfer learning**


- PSO $\approx 53,47$

- GSA $\approx 33,57$

- **Com transfer learning:**

- PSO $\approx 84,44$

- GSA $\approx 42,22$



CONJUNTO DE DADOS INDEPENDENTES

Accuracy: 84.44%

Especificidade: 84.44%


Sensibilidade: 88.98%

Matriz de Confusão: $\begin{bmatrix} 34 & 0 & 0 \\ 0 & 34 & 0 \\ 14 & 0 & 8 \end{bmatrix}$

O modelo treinado **com Transfer Learning** manteve um desempenho **consistente** ao ser avaliado em por um conjunto de dados independente.



CONCLUSÃO



Com base nos resultados obtidos, o algoritmo **GSA** demonstrou ser **mais eficaz** na procura pelos melhores hiperparâmetros para a tarefa em questão.

A utilização de **Transfer Learning**, neste caso, resultou em modelos com **melhor desempenho** em comparação com o treino sem transfer learning.

GSA com Transfer Learning destacou-se como a **melhor combinação** de algoritmo de otimização e abordagem de aprendizagem.

Transfer Learning é uma estratégia eficaz para tarefas de classificação de imagens, permitindo que o modelo aproveite o **conhecimento retirado de conjuntos de dados maiores**.